Formulario de Probabilidad e Inferencia

Material originalmente compilado por William Chen y Joe Blitzstein. Ampliado sustancialmente con extractos del Statistics Cookbook de Matthias Vallentin, adaptado al español manteniendo el rigor Por Roberto León Landeros. Este trabajo se distribuye bajo la licencia Creative Commons Atribución-NoComercial-CompartirIgual 4.0 Internacional (CC BY-NC-SA 4.0)

Última actualización April 8, 2026

Conteo y Combinatoria

Regla de la Multiplicación

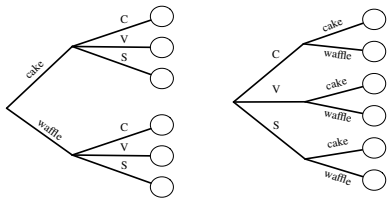

Para un experimento compuesto con múltiples componentes, si la componente i tiene n_i posibles resultados, el total de resultados para el experimento completo de r componentes es el producto de las cardinalidades individuales:

$$N = n_1 \times n_2 \times \cdots \times n_r = \prod_{i=1}^{r} n_i$$

Tabla de Muestreo

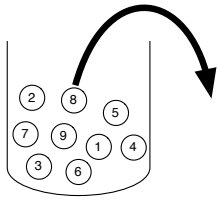

Opciones de extracción de una muestra de tamaño n desde una población $S = \{1, \ldots, s\}$ de tamaño s:

Muestra n de pob. s	Con Reemplazo	Sin Reemplazo
Con Orden	s^n	$(s)_n = \frac{s!}{(s-n)!}$
Sin Orden	$\binom{n+s-1}{s-1}$	$\binom{s}{n} = \frac{s!}{n!(s-n)!}$

Particiones y Asignaciones (Bolas en Urnas)

Números de Stirling (2da especie) $\left\{ {n \atop k} \right\}$: Formas de particionar n elementos en k subconjuntos no vacíos. $\left\{ {n \atop k} \right\} = k \left\{ {n-1 \atop k} \right\} + \left\{ {n-1 \atop k-1} \right\}$.

Asignación de n bolas a m urnas:

Bolas	Urnas	Cualquier asig.	Muestreo s.r. (Inyect.)
Dist.	Dist.	m^n	$\frac{m!}{(m-n)!}$
Indist.	Dist.	$\binom{m+n-1}{n}$	$\binom{m}{n}$
Dist.	Indist.	$\sum_{k=1}^{m} \left\{ {n \atop k} \right\}$	1 si $m \geq n$

Definiciones Adicionales de Probabilidad

Clásica (Laplace) Si los elementos son equiprobables: $P(A) = \frac{\text{casos favorables}}{\text{casos totales}} = \frac{\#A}{\#\Omega}$

Frecuencia Relativa $h_n(A) = \frac{m}{n}$ (frecuencia absoluta entre total).

Geométrica $P(A) = \frac{m(A)}{m(\Omega)}$, donde m denota la medida geométrica (longitud, área o volumen).

Expansiones Algebraicas

Binomio de Newton: $(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k b^{n-k}$

Coeficiente Multinomial: $\binom{n}{n_1, n_2, \ldots, n_k} = \frac{n!}{n_1! n_2! \ldots n_k!}$

Teorema Multinomial:
$(a_1 + \cdots + a_m)^n = \sum_{n_1 + \cdots + n_m = n} \binom{n}{n_1, \ldots, n_m} a_1^{n_1} \ldots a_m^{n_m}$

Fundamentos Teóricos

Operaciones y Álgebra de Conjuntos

Leyes de Morgan (Dualidad) $(A \cup B)^c = A^c \cap B^c$ y $(A \cap B)^c = A^c \cup B^c$

Diferencia $A \setminus B = A \cap B^c$

Diferencia Simétrica $A \triangle B = (A \setminus B) \cup (B \setminus A) = (A \cup B) \setminus (A \cap B)$

Identidades de Unión $A \cup B =$
$A \cup (B \cap A^c) = (A \cap B^c) \cup (B \cap A^c) \cup (A \cap B)$

Propiedades Distributivas $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$
$(A \cap B) \cup C = (A \cup C) \cap (B \cup C)$

Sistema Axiomático de Kolmogorov

Sea P una función sobre una σ-álgebra $\mathfrak{F}$:

1. $\Omega \in \mathfrak{F}$
2. $A \in \mathfrak{F} \implies A^c \in \mathfrak{F}$
3. $\bigcup_{i=1}^{\infty} A_i \in \mathfrak{F}$

Los axiomas de la medida de probabilidad P son:

Axioma I (No negatividad) $0 \leq P(A) \leq 1$

Axioma II (Certeza) $P(\Omega) = 1$

Axioma III (Aditividad finita) Si $A \cap B = \emptyset$, $P(A \cup B) = P(A) + P(B)$

Axioma IV (σ-aditividad) Para $\{A_i\}_{i=1}^{\infty}$ ajenos, $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$

Teoremas y Reglas Básicas

Imposibilidad $P(\emptyset) = 0$

Complemento $P(A^c) = 1 - P(A)$

Monotonía Si $A \subset B \implies P(A) \leq P(B)$

Diferencia Si $A \subset B \implies P(B \setminus A) = P(B) - P(A)$

Resta general $P(A \setminus B) = P(A) - P(A \cap B)$

Desigualdad de Boole $P(\bigcup_{i=1}^{n} A_i) \leq \sum_{i=1}^{n} P(A_i)$

Des. de Bonferroni $P(\bigcup_{i=1}^{n} A_i) \geq \sum_{i=1}^{n} P(A_i) - \sum_{i<j} P(A_i \cap A_j)$

Continuidad Si $A_n \uparrow A \implies P(A) = \lim_{n \to \infty} P(A_n)$

Probabilidad Condicional

Independencia

Eventos Independientes A y B son independientes si conocer la ocurrencia de A no provee información sobre B. Equivalencias:

$$P(A \cap B) = P(A)P(B)$$
$$P(A|B) = P(A)$$
$$P(B|A) = P(B)$$

Independencia Condicional A y B son condicionalmente independientes dado C si $P(A \cap B|C) = P(A|C)P(B|C)$. No implica independencia absoluta, ni viceversa.

Probabilidades Conjuntas, Marginales y Condicionales

Probabilidad Conjunta $P(A \cap B)$ o $P(A, B)$ – Probabilidad de que sucedan A y B.

Probabilidad Marginal $P(A)$ – Probabilidad incondicional.

Probabilidad Condicional $P(A|B) = \frac{P(A \cap B)}{P(B)}$ (para $P(B) > 0$). Satisface todos los axiomas de Kolmogorov.

Probabilidad de Intersecciones y Uniones

Regla de la Cadena (Multiplicación)

$$P(A_1 \cap \cdots \cap A_n) = P(A_1)P(A_2|A_1) \ldots P(A_n|A_1 \ldots A_{n-1})$$

$$P\Big(\bigcap_{i=1}^{n} A_i\Big) = \prod_{i=1}^{n} P\Big(A_i \Big| \bigcap_{j=1}^{i-1} A_j\Big)$$

Inclusión-Exclusión (Uniones) Para 2 eventos:
$P(A \cup B) = P(A) + P(B) - P(A \cap B)$
Para n eventos: $P(\bigcup_{i=1}^{n} A_i) = \sum_{r=1}^{n} (-1)^{r-1} S_r^n$
Donde $S_r^n = \sum_{1 \leq i_1 < \cdots < i_r \leq n} P(A_{i_1} \cap \cdots \cap A_{i_r})$

Paradoja de Simpson

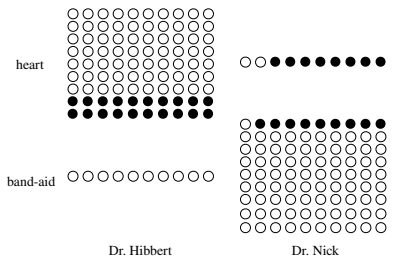

Es analíticamente posible observar:

$$P(A|B, C) < P(A|B^c, C) \text{ y } P(A|B, C^c) < P(A|B^c, C^c)$$
$$\text{pero de forma global: } P(A|B) > P(A|B^c).$$

Ley de Probabilidad Total (LOTP)

Sea $\{B_1, \ldots, B_n\}$ una partición del espacio muestral (ajenos mutuamente, unión igual a Ω).

$$P(A) = P(A|B_1)P(B_1) + \cdots + P(A|B_n)P(B_n) = \sum_{i=1}^{n} P(A|B_i)P(B_i)$$

$$P(A) = P(A \cap B_1) + \cdots + P(A \cap B_n) = \sum_{i=1}^{n} P(A \cap B_i)$$

Para **LOTP con condicionamiento extra** C:

$$P(A|C) = \sum_{i=1}^{n} P(A|B_i, C)P(B_i|C)$$

Teorema de Bayes

Inversión Condicional:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)P(A)}{\sum_{i=1}^{n} P(B|A_i)P(A_i)}$$

Con condicionamiento adicional:

$$P(A|B,C) = \frac{P(B|A,C)P(A|C)}{P(B|C)}$$

Forma de Momios (Odds) de Bayes:

$$\frac{P(A|B)}{P(A^c|B)} = \frac{P(B|A)}{P(B|A^c)}\frac{P(A)}{P(A^c)}$$

Variables Aleatorias Discretas

PMF, CDF e Independencia

Función de Masa de Probabilidad (PMF) Devuelve la probabilidad de que una V.A. *discreta* tome un valor específico x.

$$p_X(x) = P(X = x)$$

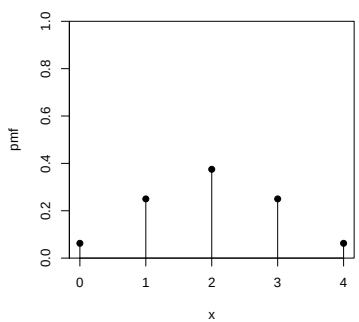

Condiciones: $p_X(x) \geq 0$ y $\sum_x p_X(x) = 1$.

Función de Distribución Acumulada (CDF) Probabilidad de que una V.A. sea menor o igual a x.

$$F_X(x) = P(X \leq x)$$

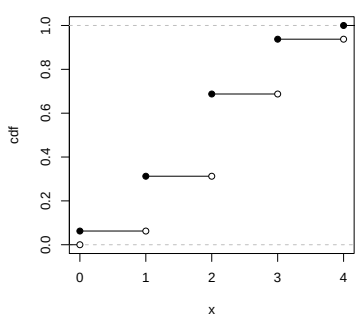

Monótona creciente, continua por la derecha, $\lim_{x\to-\infty} F_X(x) = 0$, $\lim_{x\to\infty} F_X(x) = 1$.

Independencia de V.A. V.A. X y Y son independientes si conocer el valor de una no brinda información de la otra. Para variables discretas, para todo x, y: $P(X = x, Y = y) = P(X = x)P(Y = y)$

Valor Esperado e Indicadoras

Valor Esperado y Linealidad

Esperanza Medida central o promedio ponderado de la distribución. Para X discreta con soporte $\{x_1, x_2, \dots\}$:

$$E(X) = \sum_i x_i P(X = x_i)$$

X	Y	$X+Y$
3	4	7
2	2	4
6	8	14
10	23	33
1	–3	–2
1	0	1
5	9	14
4	1	5
...	...	...

$$\frac{1}{n}\sum_{i=1}^{n} x_i \quad + \quad \frac{1}{n}\sum_{i=1}^{n} y_i \quad = \quad \frac{1}{n}\sum_{i=1}^{n}(x_i + y_i)$$

$$E(X) \quad + \quad E(Y) \quad = \quad E(X+Y)$$

Linealidad Para V.A. X, Y y constantes a, b, c:

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

Misma distribución Si X y Y comparten distribución, $E(X) = E(Y)$ y $E(g(X)) = E(g(Y))$.

Valor Esperado Condicional Expectativa ponderada sobre un evento condicional A:

$$E(X|A) = \sum_x xP(X = x|A)$$

Variables Indicadoras

Toman valor 1 si el evento sucede, 0 en caso contrario.

$$I_A = \begin{cases} 1 & \text{si } A \text{ ocurre} \\ 0 & \text{si } A^c \text{ ocurre} \end{cases}$$

Propiedades: $I_A^2 = I_A$, $I_A I_B = I_{A\cap B}$, $I_{A\cup B} = I_A + I_B - I_A I_B$.
Distribución: $I_A \sim \text{Bern}(p)$ con $p = P(A)$.
Puente Fundamental: $E(I_A) = P(A)$.
Varianza y Covarianza: $\text{Var}(I_A) = P(A)(1 - P(A))$, $\text{Cov}(I_A, I_B) = P(A \cap B) - P(A)P(B)$.

Varianza y Desviación Estándar

$$\text{Var}(X) = E\left((X - E(X))^2\right) = E(X^2) - (E(X))^2$$

$$\text{SD}(X) = \sqrt{\text{Var}(X)}$$

V.A. Continuas, LOTUS, UoU

Variables Aleatorias Continuas (CRVs)

Probabilidad en intervalos

$$P(a \leq X \leq b) = F_X(b) - F_X(a)$$

Para la Normal Estándar $Z \sim \mathcal{N}(0,1)$, la probabilidad es $\Phi(b) - \Phi(a)$.

Función de Densidad de Probabilidad (PDF) La derivada de la CDF.

$$f(x) = \frac{d}{dx}F(x) \implies F(x) = \int_{-\infty}^{x} f(t)dt$$

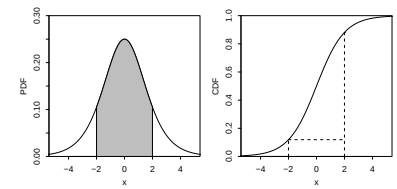

Debe integrar a 1 y ser no-negativa.

Valor Esperado Análogo al caso discreto pero con integral.

$$E(X) = \int_{-\infty}^{\infty} xf(x)dx$$

LOTUS (Ley del Cambio de Variable para la Esperanza)

Facilita hallar el valor esperado de una función dependiente de X, $g(X)$, operando sobre la PDF o PMF de X. Discreto: $E(g(X)) = \sum_x g(x)P(X = x)$ Continuo: $E(g(X)) = \int_{-\infty}^{\infty} g(x)f(x)dx$

Universalidad de la Uniforme (UoU)

Al evaluar una V.A. continua en su propia CDF, resulta en una Uniforme. Si X tiene CDF F, entonces $F(X) \sim \text{Unif}(0,1)$.
Inversamente, si $U \sim \text{Unif}(0,1)$, entonces $F^{-1}(U)$ tiene distribución F. Esto facilita la simulación computacional de V.A.

Momentos y Funciones Generadoras

Momentos

Describen la forma de la distribución. Para V.A. estandarizada $Z = \frac{X-\mu}{\sigma}$:

Media (1er momento) $E(X) = \mu_1$

Varianza (2do central) $\text{Var}(X) = \mu_2 - \mu_1^2$

Asimetría (Skewness) $\text{Skew}(X) = E(Z^3)$

Curtosis $\text{Kurt}(X) = E(Z^4) - 3$

Función Generadora de Momentos (MGF)

MGF Definida como $M_X(t) = E(e^{tX})$.

Obtención de Momentos La k-ésima derivada evaluada en 0 otorga el k-ésimo momento: $\mu_k = E(X^k) = M_X^{(k)}(0)$. Basado en expansión de Taylor: $M_X(t) = \sum_{k=0}^{\infty} \frac{E(X^k)t^k}{k!}$.

Transformación Lineal Para $Y = aX + b$, $M_Y(t) = e^{bt}M_X(at)$.

Unicidad La MGF determina unívocamente la distribución de probabilidad (si existe).

Suma de Independientes Si $X \perp\!\!\!\perp Y$: $M_{X+Y}(t) = M_X(t)M_Y(t)$

Funciones de Densidad y Masa Conjuntas

Distribuciones Conjuntas

CDF Conjunta: $F_{X,Y}(x,y) = P(X \leq x, Y \leq y)$
PMF Conjunta: $p_{X,Y}(x,y) = P(X = x, Y = y)$
PDF Conjunta: $f_{X,Y}(x,y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x,y)$

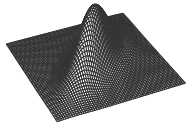

Distribuciones Condicionales y Regla de Bayes

Para discretas:
$P(Y = y|X = x) = \frac{P(X=x,Y=y)}{P(X=x)} = \frac{P(X=x|Y=y)P(Y=y)}{P(X=x)}$
Para continuas: $f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)} = \frac{f_{X|Y}(x|y)f_Y(y)}{f_X(x)}$

Distribuciones Marginales

Obtención de distribución aislada integrando/sumando la variable indeseada. Discreta: $P(X = x) = \sum_y P(X = x, Y = y)$
Continua: $f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)dy$

LOTUS Multivariado

Discreto: $E(g(X,Y)) = \sum_x \sum_y g(x,y)P(X = x, Y = y)$
Continua: $E(g(X,Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y)f_{X,Y}(x,y)dxdy$

Covarianza y Transformaciones

Covarianza y Correlación

Covarianza Analogo multivariado de varianza.

$$\mathrm{Cov}(X,Y) = E((X - E(X))(Y - E(Y))) = E(XY) - E(X)E(Y)$$

Correlación Covarianza estandarizada $[-1, 1]$.

$$\mathrm{Corr}(X,Y) = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\mathrm{Var}(Y)}}$$

Independencia $X \perp\!\!\!\perp Y \implies \mathrm{Cov}(X,Y) = 0$. El recíproco suele ser falso (salvo excepciones como Normal Multivariada).

Varianza de Sumas $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\mathrm{Cov}(X,Y)$
Para una sumatoria genérica con variables con relaciones idénticas (simetría):

$$\mathrm{Var}\Big(\sum_{i=1}^{n} X_i\Big) = \sum_{i=1}^{n} \mathrm{Var}(X_i) + 2\sum_{i<j} \mathrm{Cov}(X_i, X_j)$$

Propiedades Bilineales $\mathrm{Cov}(aX + c, bY + d) = ab\mathrm{Cov}(X,Y)$
$\mathrm{Cov}(X+Y, Z+W) = \mathrm{Cov}(X,Z) + \mathrm{Cov}(X,W) + \mathrm{Cov}(Y,Z) + \mathrm{Cov}(Y,W)$

Transformación 1D

Para $Y = g(X)$ donde g es monótona y derivable:

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

Transformaciones Multivariadas

Para V.A. (U,V) con PDF conjunta y $(X,Y) = g(U,V)$, el determinante de la matriz Jacobiana es fundamental para cambiar el dominio de densidad.

$$J = \begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{pmatrix}$$

$$f_{X,Y}(x,y) = f_{U,V}(u,v)|\det(J)|$$

Convoluciones

Integral para la PDF de la suma de dos variables continuas independientes X, Y:

$$f_{X+Y}(t) = \int_{-\infty}^{\infty} f_X(x)f_Y(t-x)dx$$

Proceso de Poisson

Definición Tasas de eventos modeladas en intervalos temporales λ.

1. Los eventos en un intervalo t siguen $\mathrm{Pois}(\lambda t)$.
2. Incrementos en intervalos disjuntos son independientes.

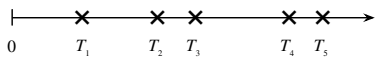

Superposición y Muestreo

1. **Superposición:** Si $N_1(t) \sim PP(\lambda_1)$ y $N_2(t) \sim PP(\lambda_2)$ independientes, entonces $N_1(t) + N_2(t) \sim PP(\lambda_1 + \lambda_2)$.
2. **Muestreo (Thinning):** Si $N \sim \mathrm{Pois}(\lambda)$ y cada evento se clasifica como tipo i con prob p_i, entonces los conteos N_i son independientes y $N_i \sim \mathrm{Pois}(\lambda p_i)$.

Dualidad Conteo-Tiempo El tiempo hasta el primer evento sigue una distribución Exponencial $\mathrm{Expo}(\lambda)$, ya que el evento de esperar t horas equivale a observar 0 llegadas en t horas ($N_t = 0$). Los tiempos de inter-llegadas son i.i.d. $\mathrm{Expo}(\lambda)$.

Estadísticos de Orden

Definición Sean $X_1, \ldots, X_n$ variables aleatorias i.i.d. Al ordenarlas de menor a mayor, $X_{(i)}$ denota el i-ésimo estadístico de orden. El mínimo es $X_{(1)}$ y el máximo $X_{(n)}$. Suelen exhibir dependencia estadística.

Distribución La CDF y PDF del elemento $X_{(i)}$ están dadas por:

$$F_{X_{(i)}}(x) = \sum_{k=i}^{n} \binom{n}{k} F(x)^k (1 - F(x))^{n-k}$$

$$f_{X_{(i)}}(x) = n\binom{n-1}{i-1} F(x)^{i-1}(1 - F(x))^{n-i} f(x)$$

Estadísticos Ordenados Uniformes El componente j-ésimo de $U_1, \ldots, U_n \sim \mathrm{Unif}(0,1)$ distribuye $U_{(j)} \sim \mathrm{Beta}(j, n-j+1)$.

Esperanza Condicional

Condicionada a un Evento Esperanza dado el evento A. Resulta en un valor escalar determinista.

Discreta	Continua
$E(Y) = \sum_y yP(Y = y)$	$E(Y) = \int_{-\infty}^{\infty} yf_Y(y)dy$
$E(Y\|A) = \sum_y yP(Y = y\|A)$	$E(Y\|A) = \int_{-\infty}^{\infty} yf(y\|A)dy$

Condicionada a una V.A. El término $E(Y|X)$ es una función matemática de la variable aleatoria X. Únicamente colapsa a una constante si son independientes ($X \perp\!\!\!\perp Y$).

Propiedades Analíticas

1. $E(Y|X) = E(Y)$ si $X \perp\!\!\!\perp Y$.
2. $E(h(X)W|X) = h(X)E(W|X)$ (extracción de escalares conocidos).
3. $E(E(Y|X)) = E(Y)$ (Ley de Adam).

Ley de Adam (Esperanza Total)

$$E(Y) = \sum_{i=1}^{n} E(Y|A_i)P(A_i)$$

Ley de Eve (Varianza Total)

$$\mathrm{Var}(Y) = E(\mathrm{Var}(Y|X)) + \mathrm{Var}(E(Y|X))$$

Teoremas Límite Clásicos

Tipos de Convergencia

En Distribución (Ley) $X_n \xrightarrow{D} X \iff \lim_{n\to\infty} F_n(t) = F(t)$

En Probabilidad $X_n \xrightarrow{P} X \iff \lim_{n\to\infty} P(|X_n - X| > \varepsilon) = 0$

Casi Segura $X_n \xrightarrow{a.s.} X \iff P(\lim_{n\to\infty} X_n = X) = 1$

Media Cuadrática (L_2)
$X_n \xrightarrow{qm} X \iff \lim_{n\to\infty} E((X_n - X)^2) = 0$

Jerarquía: $qm \implies P \implies D$ y $a.s. \implies P$.

Teorema de Slutsky

Si $X_n \xrightarrow{D} X$ y $Y_n \xrightarrow{P} c$:

$$X_n + Y_n \xrightarrow{D} X + c \quad \text{y} \quad X_nY_n \xrightarrow{D} cX$$

Ley de los Grandes Números (LLN)

Para un conjunto grande de V.A. X_i i.i.d con media μ, la media muestral $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge directamente a μ conforme $n \to \infty$ (en probabilidad para WLLN y casi segura para SLLN).

Teorema del Límite Central (CLT)

Las sumatorias y promedios muestrales de V.A. convergen asintóticamente hacia la distribución Normal, indistintamente de su distribución de origen.

$$Y = \sum X_i \dot{\sim} \mathcal{N}(n\mu_X, n\sigma_X^2)$$

$$\bar{X}_n \dot{\sim} \mathcal{N}(\mu_X, \sigma_X^2/n)$$

Estandarización Asintótica:

$$\frac{\sqrt{n}(\bar{X}_n - \mu_X)}{\sigma_X} \xrightarrow{D} \mathcal{N}(0,1)$$

Inferencia Estadística

Estimación Puntual y Propiedades

Sesgo (Bias) $\text{Bias}(\hat{\theta}_n) = E(\hat{\theta}_n) - \theta$.

Consistencia $\hat{\theta}_n \xrightarrow{P} \theta$.

Error Cuadrático Medio (MSE) $E((\hat{\theta}_n - \theta)^2) = \text{Bias}^2 + \text{Var}(\hat{\theta}_n)$.

Suficiencia $T(X)$ es suficiente si la distribución condicional de los datos dado T no depende de θ.

T. de Factorización (Fisher-Neyman) $T(X)$ es suficiente para $\theta \iff f(x|\theta) = g(T(x), \theta)h(x)$.

Eficiencia Asintótica Un estimador es eficiente si su varianza alcanza la Cota de Cramér-Rao.

Mejora de Rao-Blackwell Sea $\hat{\theta}$ un estimador insesgado y T un estadístico suficiente. Entonces $\eta = E(\hat{\theta}|T)$ es un estimador insesgado con $\text{Var}(\eta) \leq \text{Var}(\hat{\theta})$.

Información de Fisher y Cota Inferior

Información de Fisher $I(\theta) = -E\left(\frac{\partial^2}{\partial\theta^2} \log f(X;\theta)\right)$.

Cota de Cramér-Rao Para cualquier estimador insesgado $W(X)$ de θ:

$$\text{Var}(W) \geq \frac{1}{nI(\theta)}$$

Intervalos de Confianza (IC)

Media (var. conocida) $\bar{X} \pm z_{\alpha/2}\frac{\sigma}{\sqrt{n}}$

Media (var. desconocida) $\bar{X} \pm t_{\alpha/2,n-1}\frac{s}{\sqrt{n}}$

Proporción $\hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

Método de Momentos (MoM)

Igualar los momentos poblacionales teóricos $\alpha_j(\theta) = E(X^j)$ con los momentos muestrales $\hat{\alpha}_j = \frac{1}{n}\sum X_i^j$ y resolver para θ.

Máxima Verosimilitud (MLE)

Función de Verosimilitud $L(\theta) = \prod_{i=1}^n f(X_i;\theta)$

Log-Verosimilitud $\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(X_i;\theta)$

Estimador MLE $\hat{\theta}_n = \sup_\theta L(\theta)$.

Propiedades Asintóticas Bajo condiciones de regularidad: $\hat{\theta}_{MLE} \xrightarrow{D} \mathcal{N}(\theta, \frac{1}{nI(\theta)})$. Esto conecta el MLE con la Cota de Cramér-Rao y explica por qué es "eficiente".

Información de Fisher $I(\theta) = \text{Var}\left(\frac{\partial}{\partial\theta}\log f(X;\theta)\right) = -E\left(\frac{\partial^2}{\partial\theta^2}\log f(X;\theta)\right)$. Para la muestra entera: $I_n(\theta) = nI(\theta)$.

Método Delta

Si $\tau = g(\theta)$ donde g es diferenciable y $g'(\theta) \neq 0$:

$$\frac{g(\hat{\theta}_n) - g(\theta)}{|g'(\hat{\theta}_n)|\widehat{\text{se}}(\hat{\theta}_n)} \xrightarrow{D} \mathcal{N}(0,1)$$

Distribución Empírica y Bootstrap

CDF Empírica (ECDF) $\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^n I(X_i \leq x)$.

Desigualdad DKW Límite de confianza no paramétrico para F: $P(\sup_x |F(x) - \hat{F}_n(x)| > \varepsilon) \leq 2e^{-2n\varepsilon^2}$.

Bootstrap Remuestreo con reemplazo para estimar la varianza de un estadístico $T_n = g(X_1, \ldots, X_n)$.

Pruebas de Hipótesis

Nivel y Poder Error Tipo I (α): Rechazar H_0 siendo verdadera. Error Tipo II (β): No rechazar H_0 siendo falsa. Poder: $1-\beta$.

Valor-p Probabilidad de obtener un estadístico al menos tan extremo como el observado, asumiendo H_0 cierta.

Lema de Neyman-Pearson: Para H_0 vs H_1 simples, el test de región crítica $\{\frac{L(\theta_1)}{L(\theta_0)} > k\}$ es el más potente.

Pruebas Clásicas

Prueba de Wald $W = \frac{\hat{\theta}-\theta_0}{\widehat{\text{se}}}$. Rechazar H_0 si $|W| > z_{\alpha/2}$.

Likelihood Ratio Test (LRT) Compara el modelo bajo H_0 vs el general. Estadístico $\lambda = 2\log\left(\frac{L(\hat{\theta})}{L(\hat{\theta}_0)}\right)$.

LRT Multinomial Para bondad de ajuste: $\lambda(X) = 2\sum_{j=1}^k X_j \log\left(\frac{\hat{p}_j}{p_{0j}}\right) \xrightarrow{D} \chi^2_{k-1}$.

T. de Wilks: Bajo H_0 y condiciones de regularidad, $\lambda \xrightarrow{D} \chi^2_d$ donde d es la diferencia de parámetros libres.

Prueba Chi-Cuadrada de Pearson $T = \sum_{j=1}^k \frac{(X_j - E(X_j))^2}{E(X_j)} \xrightarrow{D} \chi^2_{k-1}$. Para independencia en tablas de contingencia $I \times J$, $df = (I-1)(J-1)$.

Prueba t de Student $T = \frac{\bar{X}-\mu_0}{s/\sqrt{n}} \xrightarrow{D} t_{n-1}$. Para dos muestras, se adapta el error estándar y grados de libertad.

Inferencia Bayesiana

Actualización Bayesiana

La distribución posteriori combina la información a priori con la evidencia empírica de la verosimilitud:

$$f(\theta|x^n) = \frac{f(x^n|\theta)f(\theta)}{\int f(x^n|\theta)f(\theta)d\theta} \propto L(\theta)f(\theta)$$

Verosimilitud	Parámetro	Priori Conjugada
Bernoulli / Binomial	p	Beta(α,β)
Poisson(λ)	λ	Gamma(α,β)
Normal (σ^2 conocida)	μ	Normal(μ_0,σ_0^2)
Normal (μ conocida)	σ^2	Inv-Gamma
Multinomial$(\vec{p})$	$\vec{p}$	Dirichlet$(\vec{\alpha})$
Exponencial(λ)	λ	Gamma(α,β)

Intervalos Creíbles y Factor de Bayes

Intervalo Creíble Región R_n tal que $P(\theta \in R_n|x^n) = 1-\alpha$. HPD es la región de mayor densidad posterior.

Factor de Bayes (BF) Ratio de verosimilitudes marginales de dos hipótesis. $\frac{P(H_i|x^n)}{P(H_j|x^n)} = BF_{ij} \times \frac{P(H_i)}{P(H_j)}$.

Regresión y Regularización

Regresión Lineal Simple y Múltiple

Modelo: $Y = X\beta + \epsilon$ con $E(\epsilon) = 0, \text{Var}(\epsilon) = \sigma^2 I$.

Mínimos Cuadrados (OLS) $\hat{\beta} = (X^TX)^{-1}X^TY$.

T. de Gauss-Markov: En un modelo lineal con errores de media cero, incorrelacionados y homocedásticos, el estimador OLS es el BLUE. **Supuestos (LIHN):** Linealidad, Independencia, Homocedasticidad, Normalidad de errores.

Diagnóstico de Supuestos:
No Normalidad $\implies$ Transformación de Box-Cox.
Heterocedasticidad $\implies$ Mínimos Cuadrados Ponderados (WLS).
Multicolinealidad $\implies$ Ridge Regression.

Estimación de σ^2 $\hat{\sigma}^2 = \frac{\text{RSS}}{n-k} = \frac{1}{n-k}\sum(Y_i - \hat{Y}_i)^2$.

Varianza del Estimador $\text{Var}(\hat{\beta}|X) = \sigma^2(X^TX)^{-1}$.

R Cuadrada $R^2 = 1 - \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\sum(Y_i-\hat{Y}_i)^2}{\sum(Y_i-\bar{Y})^2}$.

Regularización y Trade-off Sesgo-Varianza

Evitan el sobreajuste penalizando los coeficientes β:

Ridge (L_2): $\min \|Y - X\beta\|^2 + \lambda\|\beta\|_2^2$. Reduce la varianza ante multicolinealidad.

Lasso (L_1): $\min \|Y - X\beta\|^2 + \lambda\|\beta\|_1$. Realiza selección automática de variables (encoge $\beta_i \to 0$).

Descomposición MSE: $MSE(\hat{\theta}) = \text{Bias}^2(\hat{\theta}) + \text{Var}(\hat{\theta}) + \sigma^2_{irr}$.

Regresión Logística (GLM)

Para problemas de clasificación binaria, predice probabilidades empleando la función de enlace logit:

$$p(X) = \frac{e^{\beta_0+\beta X}}{1+e^{\beta_0+\beta X}} \implies \text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta X$$

Selección de Modelos

Penalizan la complejidad (parámetros k) para evitar sobreajuste.

AIC $AIC = 2k - 2\ell(\hat{\beta}, \hat{\sigma}^2)$

BIC $BIC = k\log n - 2\ell(\hat{\beta}, \hat{\sigma}^2)$

C_p de Mallow $\hat{R}(S) = \text{RSS} + 2k\hat{\sigma}^2$

Series de Tiempo

Ruido Blanco $w_t \sim wn(0, \sigma_w^2)$ tiene $E(w_t) = 0, \text{Var}(w_t) = \sigma_w^2$ y $\gamma(s,t) = 0$ para $s \neq t$.

Estacionariedad Fuerte La distribución conjunta es invariable bajo desplazamientos temporales.

Estacionariedad Débil Media constante y autocovarianza $\gamma(s,t)$ que solo depende del retraso $h = |s-t|$.

ACF y PACF La Función de Autocorrelación $\rho(h) = \frac{\gamma(h)}{\gamma(0)}$. La PACF remueve el efecto de lags intermedios.

Operador de Retraso (Backshift) $B^kX_t = X_{t-k}$.

Operador de Diferencia $\nabla^d = (1-B)^d$.

Modelos ARIMA (p, d, q)

AR(p) Autoregresivo $x_t = \sum_{i=1}^p \phi_i x_{t-i} + w_t$. (ACF decae asintóticamente, PACF se corta en p).

MA(q) Promedio Móvil $x_t = w_t + \sum_{j=1}^q \theta_j w_{t-j}$. (ACF se corta en q, PACF decae).

Integración (d) Diferenciación $\nabla^d = (1-B)^d$ para remover tendencias estocásticas.

Cadenas de Markov

Definición y Propiedades

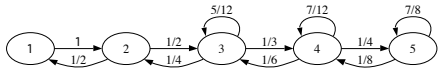

Una cadena de Markov (sobre un espacio de estados discreto) garantiza la propiedad fundamental de **pérdida de memoria**: dado el estado presente, los futuros y pasados son condicionalmente independientes.

$$P(X_{n+1} = j|X_0 \ldots, X_n = i) = P(X_{n+1} = j|X_n = i)$$

Estados recurrentes garantizan su retorno futuro, mientras que los transitorios poseen probabilidad estricta de abandono infinito. Los estados pueden ser periódicos o aperiódicos según el MCD de sus retornos de pasos.

Matriz de Transición y Distribución Estacionaria

Matriz Q donde $q_{ij} = P(X_{n+1} = j|X_n = i)$. La probabilidad de transición en m pasos es el elemento respectivo en Q^m.
Una distribución PMF $\vec{s}$ es **Estacionaria** si $\vec{s}Q = \vec{s}$. Para sistemas irreducibles y aperiódicos existe una única distribución estacionaria. El tiempo esperado de retorno a un estado i es $1/s_i$. Si $s_i q_{ij} = s_j q_{ji}$ (Ecuación de balance detallado) para todo i, j, el sistema posee Reversibilidad, lo cual implica inherentemente estacionariedad.
Ergodicidad: Una cadena es ergódica si es irreducible, aperiódica y todos sus estados son recurrentes positivos. Esto garantiza la convergencia a una única distribución estacionaria.

Métodos de Muestreo (Sampling)

Transformada Inversa Si $U \sim \text{Unif}(0, 1)$, entonces $X = F^{-1}(U)$ tiene CDF F.

Muestreo por Rechazo Para simular $f(x)$ usando $g(x)$ tal que $f(x) \leq Mg(x)$. 1. Generar $X \sim g$ y $U \sim \text{Unif}(0, 1)$. 2. Aceptar X si $U \leq \frac{f(X)}{Mg(X)}$.

Muestreo por Importancia Estima $E_f[h(X)]$ usando g: $E_f[h(X)] = \int h(x)\frac{f(x)}{g(x)}g(x)dx = E_g[h(X)w(X)]$ donde $w(x) = f(x)/g(x)$.

Teoría de Decisiones

Función de Pérdida $L(\theta, a)$ mide el costo de elegir acción a cuando el parámetro es θ. Ej: $L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$.

Riesgo Estadístico $R(\theta, \delta) = E_\theta[L(\theta, \delta(X))]$.

Riesgo de Bayes $r(\pi, \delta) = \int R(\theta, \delta)\pi(\theta)d\theta$. La regla de Bayes minimiza el riesgo promedio.

Regla Minimax Minimiza el máximo riesgo posible: $\inf_\delta \sup_\theta R(\theta, \delta)$.

Estadística No Paramétrica

Kernel Density Estimation (KDE) $\hat{f}_h(x) = \frac{1}{nh}\sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)$.

Regresión de Nadaraya-Watson Estimador de $m(x) = E(Y|X = x)$: $\hat{m}_h(x) = \frac{\sum K_h(x-X_i)Y_i}{\sum K_h(x-X_i)}$.

Distribuciones Continuas

Uniforme Unif(a, b)

Probabilidad puramente proporcional al tamaño geométrico de la región de soporte, con una densidad plana y nula en el exterior.

Normal Gaussiana $\mathcal{N}(\mu, \sigma^2)$

Distribución simétrica de mayor presencia en la naturaleza a causa del Teorema del Límite Central. Es invariante ante transformaciones de escala y traslaciones (resultando en nuevas Gaussianas). La Normal Estándar evalúa con $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0, 1)$.

Exponencial Expo(λ)

Única distribución continua con la propiedad de **pérdida de memoria** (Markoviana). Expresa el tiempo de espera hasta el próximo evento en procesos de Poisson; un tiempo esperado dictado por $1/\lambda$.
Formulación analítica: $P(X > s + t \mid X > s) = P(X > t)$.

Gamma Gamma(a, λ)

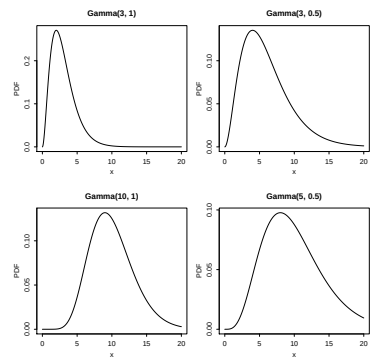

Representa el tiempo acumulado de la espera de a ocurrencias independientes en un esquema Exponencial λ.

Beta Beta(a, b)

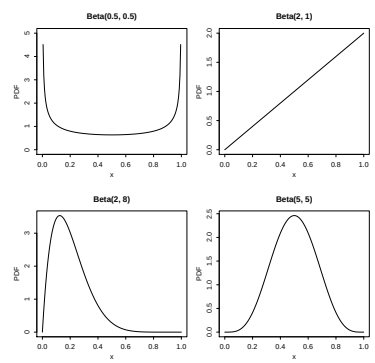

Su dominio $(0, 1)$ permite modelar probabilidades y proporciones aleatorias. Es el conjugado previo clásico de la Binomial en la inferencia Bayesiana.

Distribuciones Discretas

Bernoulli Bern(p)

Experimento aislado dual: Éxito (probabilidad p) y Fracaso $(1 - p)$.

Binomial Bin(n, p)

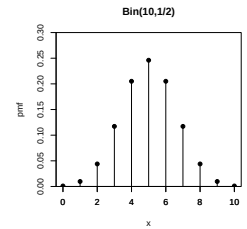

Acumula el conteo total de éxitos independientes bajo n iteraciones idénticas de variables Bernoulli. Si p es diminuto, aproxima a la de Poisson; si n es masivo, aproxima a Gaussiana.

Geométrica Geom(p) / Binomial Negativa NBin(r, p)

Registran iteraciones Bernoulli secuenciales. La Geométrica dictamina fracasos previos a obtener 1 éxito. La Binomial Negativa expande el modelo contabilizando los fracasos requeridos antes de registrar r éxitos en la iteración.

Hipergeométrica HGeom(w, b, n)

Muestreos sin reemplazo. Extrae n objetos aleatorios sobre un universo finito de w especímenes deseados y b no deseados. Carece de independencia iterativa.

Poisson Pois(λ)

Agrupa flujos continuos sobre dominios discretos. Usado típicamente para eventos extremadamente atípicos operando a escalas o volúmenes temporalmente grandes con una tasa esperada estricta.

Distribuciones Multivariadas

Multinomial Mult$_k(n, \vec{p})$

Generalización de Binomial a vectores de k categorías independientes. Marginalmente colapsan de nuevo a la versión Binomial. PMF Conjunta:

$$P(\vec{X} = \vec{n}) = \frac{n!}{\prod_{i=1}^k n_i!}\prod_{i=1}^k p_i^{n_i}$$

Normal Multivariada

Extensión métrica del comportamiento Gaussiano en k-dimensiones algebraicas. Posee la propiedad clave de que vectores sin correlación equivalen firmemente a su independencia escalar subyacente. Su función de densidad con vector de medias $\boldsymbol{\mu}$ y matriz de covarianza $\boldsymbol{\Sigma}$ es:

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k|\boldsymbol{\Sigma}|}}\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

Normal Bivariada Condicional: Para $(X_1, X_2) \sim \mathcal{N}$, el valor esperado condicional de X_1 dado $X_2 = x_2$ es:

$$E(X_1|X_2 = x_2) = \mu_1 + \rho\frac{\sigma_1}{\sigma_2}(x_2 - \mu_2)$$

$$\text{Var}(X_1|X_2 = x_2) = \sigma_1^2(1 - \rho^2)$$

Dirichlet $\mathrm{Dir}(\vec{\alpha})$

Priori conjugada de la Multinomial. Modela distribuciones de probabilidad sobre el símplex estándar. Densidad proporcional a $\prod_{i=1}^{k} x_i^{\alpha_i - 1}$.

Propiedades Esenciales

Convoluciones Lineales Elementales

Mantenido sobre el axioma de variables X e Y independientes:

1. $X \sim \mathrm{Pois}(\lambda_1), Y \sim \mathrm{Pois}(\lambda_2) \implies X + Y \sim \mathrm{Pois}(\lambda_1 + \lambda_2)$
2. $X \sim \mathrm{Bin}(n_1, p), Y \sim \mathrm{Bin}(n_2, p) \implies X + Y \sim \mathrm{Bin}(n_1 + n_2, p)$
3. $X \sim \mathrm{Gamma}(a_1, \lambda), Y \sim \mathrm{Gamma}(a_2, \lambda) \implies X + Y \sim \mathrm{Gamma}(a_1 + a_2, \lambda)$
4. $X \sim \mathcal{N}(\mu_1, \sigma_1^2), Y \sim \mathcal{N}(\mu_2, \sigma_2^2) \implies X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
5. **Teorema del Banco (Relación Beta-Gamma):** $X \sim \mathrm{Gamma}(a, \lambda), Y \sim \mathrm{Gamma}(b, \lambda) \implies \frac{X}{X+Y} \sim \mathrm{Beta}(a, b)$, donde $(X + Y) \perp\!\!\!\perp \frac{X}{X+Y}$.

Desigualdades Analíticas

1. **Cauchy-Schwarz** $|E(XY)| \leq \sqrt{E(X^2)E(Y^2)}$
2. **Markov** $P(|X| \geq a) \leq \frac{E|X|}{a}$
3. **Chebyshev** $P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$
4. **Jensen** $E(g(X)) \geq g(E(X))$ con g convexa.

Entropía e Información

Entropía de Shannon $H(X) = -\sum_x p(x) \log_2 p(x)$. Cuantifica la incertidumbre promedio.

Divergencia KL $D_{KL}(P||Q) = \sum_x P(x) \log_2 \left(\frac{P(x)}{Q(x)}\right)$. Mide la pérdida de información al aproximar P usando Q.

Información Mutua $I(X;Y) = H(X) - H(X|Y)$

Entropía Cruzada $H(P, Q) = -\sum P(x) \log Q(x)$

Fórmulas Básicas

Series Lineales y Series de Taylor

Geométrica (Finita e Infinita): $\sum_{k=0}^{n-1} r^k = \frac{1-r^n}{1-r}$ e infinidad asintótica para $|r| < 1$ como $\frac{1}{1-r}$.
Exponencial Natural: $e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!} = \lim_{n\to\infty} \left(1 + \frac{x}{n}\right)^n$

Funciones Especiales

Función Gamma: $\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx$. Propiedades: $\Gamma(t+1) = t\Gamma(t)$, $\Gamma(n) = (n-1)!$ para $n \in \mathbb{N}$ y $\Gamma(1/2) = \sqrt{\pi}$.
Función Beta: $B(x, y) = \int_0^1 t^{x-1}(1-t)^{y-1} dt = \frac{\Gamma(x)\Gamma(y)}{\Gamma(x+y)}$.

Aproximación de Stirling

Fórmula de Stirling: $n! \approx \sqrt{2\pi n}(n/e)^n$.

Familia Exponencial

Una distribución pertenece a la familia exponencial si su densidad se escribe como:

$$f(x|\theta) = h(x) \exp\left(\eta(\theta) \cdot T(x) - A(\theta)\right)$$

Donde $T(x)$ es el estadístico suficiente, $\eta(\theta)$ el parámetro natural y $A(\theta)$ la función log-partición.

F. Generadora de Probabilidad (PGF)

Para V.A. discretas no negativas X:

$$G_X(z) = E(z^X) = \sum_{k=0}^{\infty} p_k z^k$$

Momentos factoriales: $E[X(X-1)\dots(X-k+1)] = G_X^{(k)}(1)$.

Comandos R Estadísticos

Prefijo	Acción
`d...(x)`	Densidad o Masa (PDF/PMF)
`p...(q)`	Área bajo la curva (CDF)
`q...(p)`	Quantiles y cortes de probabilidad
`r...(n)`	Generador Pseudo-Aleatorio (i.i.d)

Reemplace ... con norm, binom, pois, exp, etc.

Contenido complementario

Errores Comunes y Notas de Soporte

P-hacking Ajustar α ante múltiples pruebas (Corrección de Bonferroni: $\alpha_{adj} = \alpha/n$).

Interpretación IC Frecuentista: El intervalo es aleatorio y el parámetro fijo. Bayesiano: El parámetro es aleatorio (Intervalo Creíble).

Falacia del Valor Esperado $E(g(X)) \neq g(E(X))$ a menos que g sea lineal (Jensen determina la dirección de la desigualdad).

Independencia vs. Correlación $\mathrm{Corr}(X, Y) = 0 \not\Rightarrow X \perp\!\!\!\perp Y$. La incorrelación solo mide relación lineal.

Condicionamiento $P(A|B) \neq P(B|A)$ (Falacia del fiscal).

Soporte de VA Verificar si el soporte depende de parámetros (ej. $\mathrm{Unif}(0, \theta)$); esto invalida condiciones de regularidad.

Cauchy: No posee media ni varianza definidas. Proporción de dos Normales estándar independientes (Z_1/Z_2).

Falta de Memoria: Única en Expo (cont.) y Geom (disc.).

Génesis de Distribuciones (Estructural)

- χ_n^2: Suma de n Gaussianas estándar al cuadrado $\sum_{i=1}^n Z_i^2$.
- t_n: Cociente $Z/\sqrt{V/n}$ con $V \sim \chi_n^2$.
- F_{d_1,d_2}: Cociente de dos Chi-cuadradas normalizadas $(U/d_1)/(V/d_2)$.

Muestreo MCMC (Metropolis-Hastings)

Regla de aceptación para generar muestras de $P(x)$ complejo:

$$\alpha(x \to x') = \min\left(1, \frac{P(x')Q(x|x')}{P(x)Q(x'|x)}\right)$$

Aproximaciones Asintóticas

Origen	Límite	Condición
$\mathrm{Bin}(n, p)$	$\mathrm{Pois}(\lambda = np)$	$n \to \infty, p \to 0$
$\mathrm{Bin}(n, p)$	$\mathcal{N}(np, npq)$	$np > 5, nq > 5$
$\mathrm{Pois}(\lambda)$	$\mathcal{N}(\lambda, \lambda)$	$\lambda > 20$
HGeom	$\mathrm{Bin}(n, \frac{w}{w+b})$	$w + b \gg n$
t_n	$\mathcal{N}(0, 1)$	$n \to \infty$

Evidencia del Valor-p (Criterio de Fisher)

Valor-p	Evidencia contra H_0
$p > 0.10$	No hay evidencia significativa
$0.05 < p \leq 0.10$	Evidencia marginal (débil)
$0.01 < p \leq 0.05$	Evidencia moderada
$p \leq 0.01$	Evidencia muy fuerte

Adiciones Sugeridas de Inferencia y Varianza

Guía de Decisión Estocástica:
σ conocida $\implies Z$ (Normal).
σ descon. $(n < 30) \implies t$ (Student).
Comp. Varianzas $\implies F$ (Fisher).
Indep./Ajuste $\implies \chi^2$ (Chi-cuadrada).

Relaciones Útiles:
$\mathrm{Bin}(1, p) \equiv \mathrm{Bern}(p)$.
$\mathrm{Gamma}(1, \lambda) \equiv \mathrm{Expo}(\lambda)$.
$\mathrm{Gamma}(n/2, 1/2) \equiv \chi_n^2$.

Varianza de la Resta:
$\mathrm{Var}(aX - bY) = a^2\mathrm{Var}(X) + b^2\mathrm{Var}(Y) - 2ab\mathrm{Cov}(X, Y)$.

FCPF (Muestreo s.r.): factor de corrección para población finita: $\sqrt{\frac{N-n}{N-1}}$.

Interpretación Beta Bayes: En $\mathrm{Beta}(\alpha, \beta)$, $\alpha - 1$ son éxitos previos y $\beta - 1$ son fracasos previos.

Identidades Matriciales Útiles

En el contexto de la Normal Multivariada $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$:

1. $(\mathbf{X} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_k^2$.
2. $\mathrm{Var}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T$.
3. Si $\boldsymbol{\Sigma}$ es diagonal $\implies$ componentes independientes.

Inferencia y Métodos Avanzados

Cota de Cramér-Rao: $\mathrm{Var}(\hat{\theta}) \geq \frac{1}{nI(\theta)}$ para insesgados.
T. de Wilks: Bajo H_0, el estadístico de razón de verosimilitud $\lambda \xrightarrow{D} \chi_d^2$.
Bayes Kernel: Posterior $\propto$ Verosimilitud $\times$ Prior.
Método Delta Multi: Si $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} \mathcal{N}(0, \Sigma)$:

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{D} \mathcal{N}(0, \nabla g(\theta)^T \Sigma \nabla g(\theta))$$

Jerarquía de Convergencia

$$\begin{tikzcd} & a.s. \arrow[d] & \\ L_2 \arrow[r] & P \arrow[r] & D \end{tikzcd}$$

Tabla de Distribuciones

Distribución	PMF/PDF y Dominio (Soporte)	Esperanza	Varianza	MGF
Bernoulli $Bern(p)$	$P(X=1)=p, P(X=0)=q=1-p$	p	pq	$q+pe^t$
Binomial $Bin(n,p)$	$P(X=k)=\binom{n}{k}p^k q^{n-k}$ $k\in\{0,1,\dots,n\}$	np	npq	$(q+pe^t)^n$
Geométrica $Geom(p)$	$P(X=k)=q^k p$ (fallos) $k\in\{0,1,\dots\}$	q/p	q/p^2	$\frac{p}{1-qe^t}$
Binomial Negativa $NBin(r,p)$	$P(X=n)=\binom{n+r-1}{n}p^r q^n$ $n\in\{0,1,\dots\}$	rq/p	rq/p^2	$(\frac{p}{1-qe^t})^r$
Hipergeométrica $HGeom(w,b,n)$	$P(X=k)=\frac{\binom{w}{k}\binom{b}{n-k}}{\binom{w+b}{n}}$ $k\in\{0,1,\dots,n\}$	$\frac{nw}{w+b}$	$n\frac{w}{w+b}\frac{b}{w+b}\frac{w+b-n}{w+b-1}$	Intratable
Poisson $Pois(\lambda)$	$P(X=k)=\frac{e^{-\lambda}\lambda^k}{k!}$ $k\in\{0,1,\dots\}$	λ	λ	$e^{\lambda(e^t-1)}$
Uniforme $Unif(a,b)$	$f(x)=\frac{1}{b-a}$ $x\in(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\frac{e^{tb}-e^{ta}}{t(b-a)}$
Normal $N(\mu,\sigma^2)$	$f(x)=\frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$ $x\in(-\infty,\infty)$	μ	σ^2	$e^{\mu t+\frac{\sigma^2 t^2}{2}}$
Exponencial $Expo(\lambda)$	$f(x)=\lambda e^{-\lambda x}$ $x\in[0,\infty)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{\lambda}{\lambda-t}$
Gamma $Gamma(\alpha,\lambda)$	$f(x)=\frac{\lambda^\alpha x^{\alpha-1}e^{-\lambda x}}{\Gamma(\alpha)}$ $x\in[0,\infty)$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	$(\frac{\lambda}{\lambda-t})^\alpha$
Beta $Beta(a,b)$	$f(x)=\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}x^{a-1}(1-x)^{b-1}$ $x\in(0,1)$	$\frac{a}{a+b}$	$\frac{ab}{(a+b)^2(a+b+1)}$	Intratable
Log Normal $LN(\mu,\sigma^2)$	$f(x)=\frac{1}{x\sigma\sqrt{2\pi}}e^{-\frac{(\ln x-\mu)^2}{2\sigma^2}}$ $x>0$	$e^{\mu+\sigma^2/2}$	$(e^{\sigma^2}-1)e^{2\mu+\sigma^2}$	No existe
Weibull $W(k,\lambda)$	$f(x)=\frac{k}{\lambda}(\frac{x}{\lambda})^{k-1}e^{-(x/\lambda)^k}$ $x\geq 0$	$\lambda\Gamma(1+1/k)$	$\lambda^2[\Gamma(1+2/k)-\Gamma^2(1+1/k)]$	Ver Stirling
Pareto $Pa(x_m,\alpha)$	$f(x)=\frac{\alpha x_m^\alpha}{x^{\alpha+1}}$ $x\geq x_m$	$\frac{\alpha x_m}{\alpha-1}(\alpha>1)$	$\frac{x_m^2\alpha}{(\alpha-1)^2(\alpha-2)}(\alpha>2)$	No existe
Laplace $L(\mu,b)$	$f(x)=\frac{1}{2b}e^{-\frac{\lvert x-\mu\rvert}{b}}$ $x\in(-\infty,\infty)$	μ	$2b^2$	$\frac{e^{\mu t}}{1-b^2t^2}(\lvert t\rvert<1/b)$
Chi-Cuadrada χ^2_n	$\frac{1}{2^{n/2}\Gamma(n/2)}x^{n/2-1}e^{-x/2}$ $x\in(0,\infty)$	n	$2n$	$(1-2t)^{-n/2}$
t de Student t_ν	$f(x)\propto(1+\frac{x^2}{\nu})^{-\frac{\nu+1}{2}}$	$0(\nu>1)$	$\frac{\nu}{\nu-2}(\nu>2)$	Intratable
F de Fisher F_{d_1,d_2}	$f(x)\propto\frac{\sqrt{\frac{(d_1x)^{d_1}d_2^{d_2}}{(d_1x+d_2)^{d_1+d_2}}}}{xB(\frac{d_1}{2},\frac{d_2}{2})}$	$\frac{d_2}{d_2-2}$	$\frac{2d_2^2(d_1+d_2-2)}{d_1(d_2-2)^2(d_2-4)}$	Intratable
Cauchy $Cauchy(x_0,\gamma)$	$f(x)=\frac{1}{\pi\gamma[1+(\frac{x-x_0}{\gamma})^2]}$ $x\in(-\infty,\infty)$	Indefinida	Indefinida	Indefinida

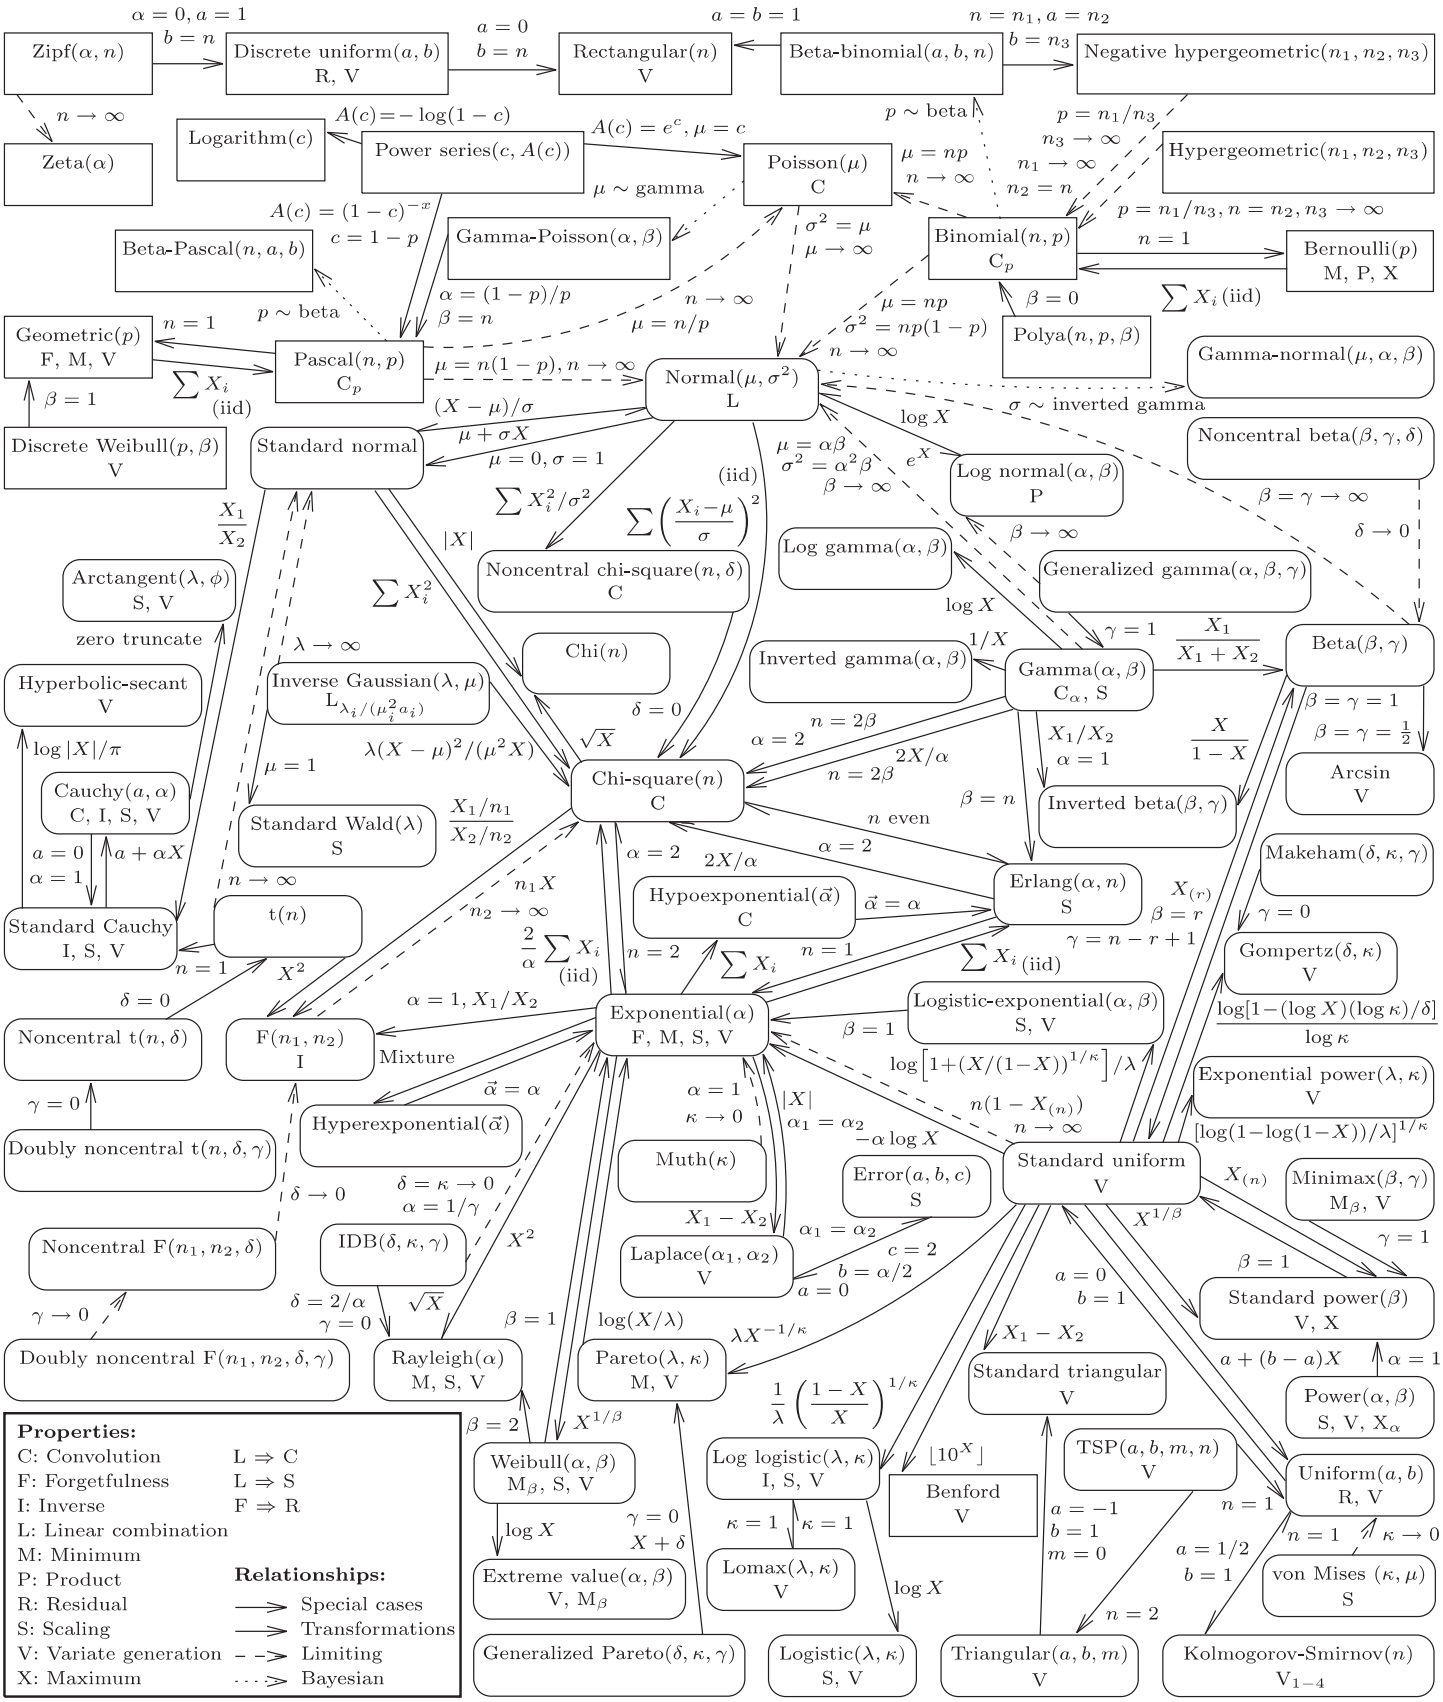
Zipf(α, n)
Discrete uniform(a, b) R, V
Rectangular(n) V
Beta-binomial(a, b, n)
Negative hypergeometric(n1, n2, n3)
Zeta(α)
Logarithm(c)
Power series(c, A(c))
Poisson(μ) C
Hypergeometric(n1, n2, n3)
Beta-Pascal(n, a, b)
Gamma-Poisson(α, β)
Binomial(n, p) Cp
Bernoulli(p) M, P, X
Geometric(p) F, M, V
Pascal(n, p) Cp
Polya(n, p, β)
Gamma-normal(μ, α, β)
Normal(μ, σ²) L
Discrete Weibull(p, β) V
Standard normal
Noncentral beta(β, γ, δ)
Log normal(α, β) P
Log gamma(α, β)
Generalized gamma(α, β, γ)
Arctangent(λ, φ) S, V
Noncentral chi-square(n, δ) C
Chi(n)
Inverted gamma(α, β)
Gamma(α, β) Cα, S
Beta(β, γ)
Hyperbolic-secant V
Inverse Gaussian(λ, μ) Lλi/(μi²ai)
Cauchy(a, α) C, I, S, V
Standard Wald(λ) S
Chi-square(n) C
Inverted beta(β, γ)
Arcsin V
Makeham(δ, κ, γ)
Standard Cauchy I, S, V
t(n)
Hypoexponential(α⃗) C
Erlang(α, n) S
Gompertz(δ, κ) V
Noncentral t(n, δ)
F(n1, n2) I
Exponential(α) F, M, S, V
Logistic-exponential(α, β) S, V
Exponential power(λ, κ) V
Doubly noncentral t(n, δ, γ)
Hyperexponential(α⃗)
Muth(κ)
Error(a, b, c) S
Standard uniform V
Minimax(β, γ) Mβ, V
Noncentral F(n1, n2, δ)
IDB(δ, κ, γ)
Laplace(α1, α2) V
Standard power(β) V, X
Doubly noncentral F(n1, n2, δ, γ)
Rayleigh(α) M, S, V
Pareto(λ, κ) M, V
Standard triangular V
Power(α, β) S, V, Xα
Weibull(α, β) Mβ, S, V
Log logistic(λ, κ) I, S, V
Benford V
TSP(a, b, m, n) V
Uniform(a, b) R, V
Extreme value(α, β) V, Mβ
Lomax(λ, κ) V
von Mises (κ, μ) S
Generalized Pareto(δ, κ, γ)
Logistic(λ, κ) S, V
Triangular(a, b, m) V
Kolmogorov-Smirnov(n) V1−4
Properties:
C: Convolution
F: Forgetfulness
I: Inverse
L: Linear combination
M: Minimum
P: Product
R: Residual
S: Scaling
V: Variate generation
X: Maximum
L ⇒ C
L ⇒ S
F ⇒ R
Relationships:
Special cases
Transformations
Limiting
Bayesian